

Descripción del Dataset

Proyecto

Predicción del Rendimiento Académico de Estudiantes

Dataset

Para el desarrollo del proyecto utilizare el conjunto de datos Student Performance Dataset.

Origen de los datos

El dataset fue obtenido del repositorio público **UCI Machine Learning Repository**.

Fuente:

Student Performance Dataset – UCI Machine Learning Repository

Autores del conjunto de datos:

- Paulo Cortez
- Alice Silva
- Leandro Almeida
- Teresa A. Gonçalves
- José Martins

El conjunto de datos fue recopilado en dos escuelas secundarias de Portugal y contiene información relacionada con características demográficas, sociales, familiares y académicas de los estudiantes.

Para este proyecto se utilizará el archivo:

student-mat.csv

correspondiente a estudiantes de la asignatura Matemática.

Descripción general del dataset

El conjunto de datos contiene información de **395 estudiantes** y **33 variables**, incluyendo características personales, familiares, sociales y académicas. Cada fila representa un estudiante y cada columna representa una característica o atributo asociado a dicho estudiante.

Características del dataset

Variable	Tipo	Descripción
school	Categórica	Escuela del estudiante
sex	Categórica	Sexo
age	Numérica	Edad
address	Categórica	Tipo de residencia
famsize	Categórica	Tamaño de la familia
Pstatus	Categórica	Estado de convivencia de los padres
Medu	Numérica	Educación de la madre
Fedu	Numérica	Educación del padre
studytime	Numérica	Tiempo de estudio semanal
failures	Numérica	Materias reprobadas previamente
schoolsup	Categórica	Apoyo escolar adicional
famsup	Categórica	Apoyo familiar
internet	Categórica	Acceso a internet
absences	Numérica	Cantidad de ausencias
G1	Numérica	Nota del primer período
G2	Numérica	Nota del segundo período
G3	Numérica	Nota final

Además de estas variables, el dataset incluye otras características relacionadas con actividades extracurriculares, relaciones familiares, salud, consumo de alcohol y tiempo libre.

Tipo de datos

El conjunto de datos contiene dos tipos principales de variables:

- Variables numéricas (edad, ausencias, tiempo de estudio, calificaciones, etc.).
- Variables categóricas (sexo, apoyo familiar, acceso a internet, entre otras).

Variable objetivo

Para transformar el problema en una tarea de clasificación binaria se construirá una nueva variable denominada Aprobado, utilizando la nota final (G3).

- Aprobado (1): $G3 \geq 10$
- Desaprobado (0): $G3 < 10$

Dado que el sistema de calificaciones del dataset corresponde al sistema educativo portugués, la escala utilizada es de 0 a 20 puntos.

Preprocesamiento previsto

Antes de entrenar los modelos se realizarán las siguientes tareas:

- Análisis exploratorio de datos.
- Verificación de valores faltantes.
- Transformación de variables categóricas.
- Creación de la variable objetivo.
- División de los datos en conjuntos de entrenamiento y prueba.

Justificación de la elección

Este dataset fue seleccionado porque presenta una problemática educativa real, posee una cantidad adecuada de registros para un proyecto académico introductorio y contiene variables que permiten analizar distintos factores asociados al rendimiento académico de los estudiantes. Además, es un conjunto de datos ampliamente utilizado, lo que facilita la comparación de resultados y la comprensión de las técnicas aplicadas.